Факультет компьютерных наук

Аналитика больших данных

Москва
2026-2027

Основы обработки естественного языка (NLP)

Лекция 1. Текст как данные

Курс “Основы NLP”

Введение в NLP и предобработка текста

- Базовая работа с текстом
- Векторизация текста
- Сверточные нейросети (CNN) и рекуррентные (RNN/LSTM)
- POS-теггинг, именованные сущности (NER)
- Seq2Seq-модели → энкодеры

Курс “Дизайн современных LLM”

Большие языковые модели и их архитектуры



Программа курса: темы 1-5

1. Текст как данные: аудит корпуса и предобработка
2. Разреженные представления и интерпретируемые бейзлайны
3. Векторные представления слов и subword-токенизация
4. Представления предложений и структура корпуса
5. Нейросетевые энкодеры текста

Программа курса: темы 6-10

6. Извлечение информации из текста

7. Современные энкодерные трансформеры и передача знаний

8. Семантический поиск и переранжирование

9. Основы генеративного NLP: языковое моделирование, Seq2Seq и механизм внимания

10. LLM в анализе текстовых данных

Курс «Основы NLP»

Вторник и четверг, 18:10. Три пары: лекция + 2 семинара.

Репозиторий курса

Работа	Содержание	Вес
ДЗ1	Классический текстовый бейзлайн	0.3
ДЗ2	Эмбеддинги и структура корпуса	0.3
ДЗ3	Семантическая близость текстов: Kaggle	0.4

Итог = 0.3 × ДЗ1 + 0.3 × ДЗ2 + 0.4 × ДЗ3. Максимум - 10.

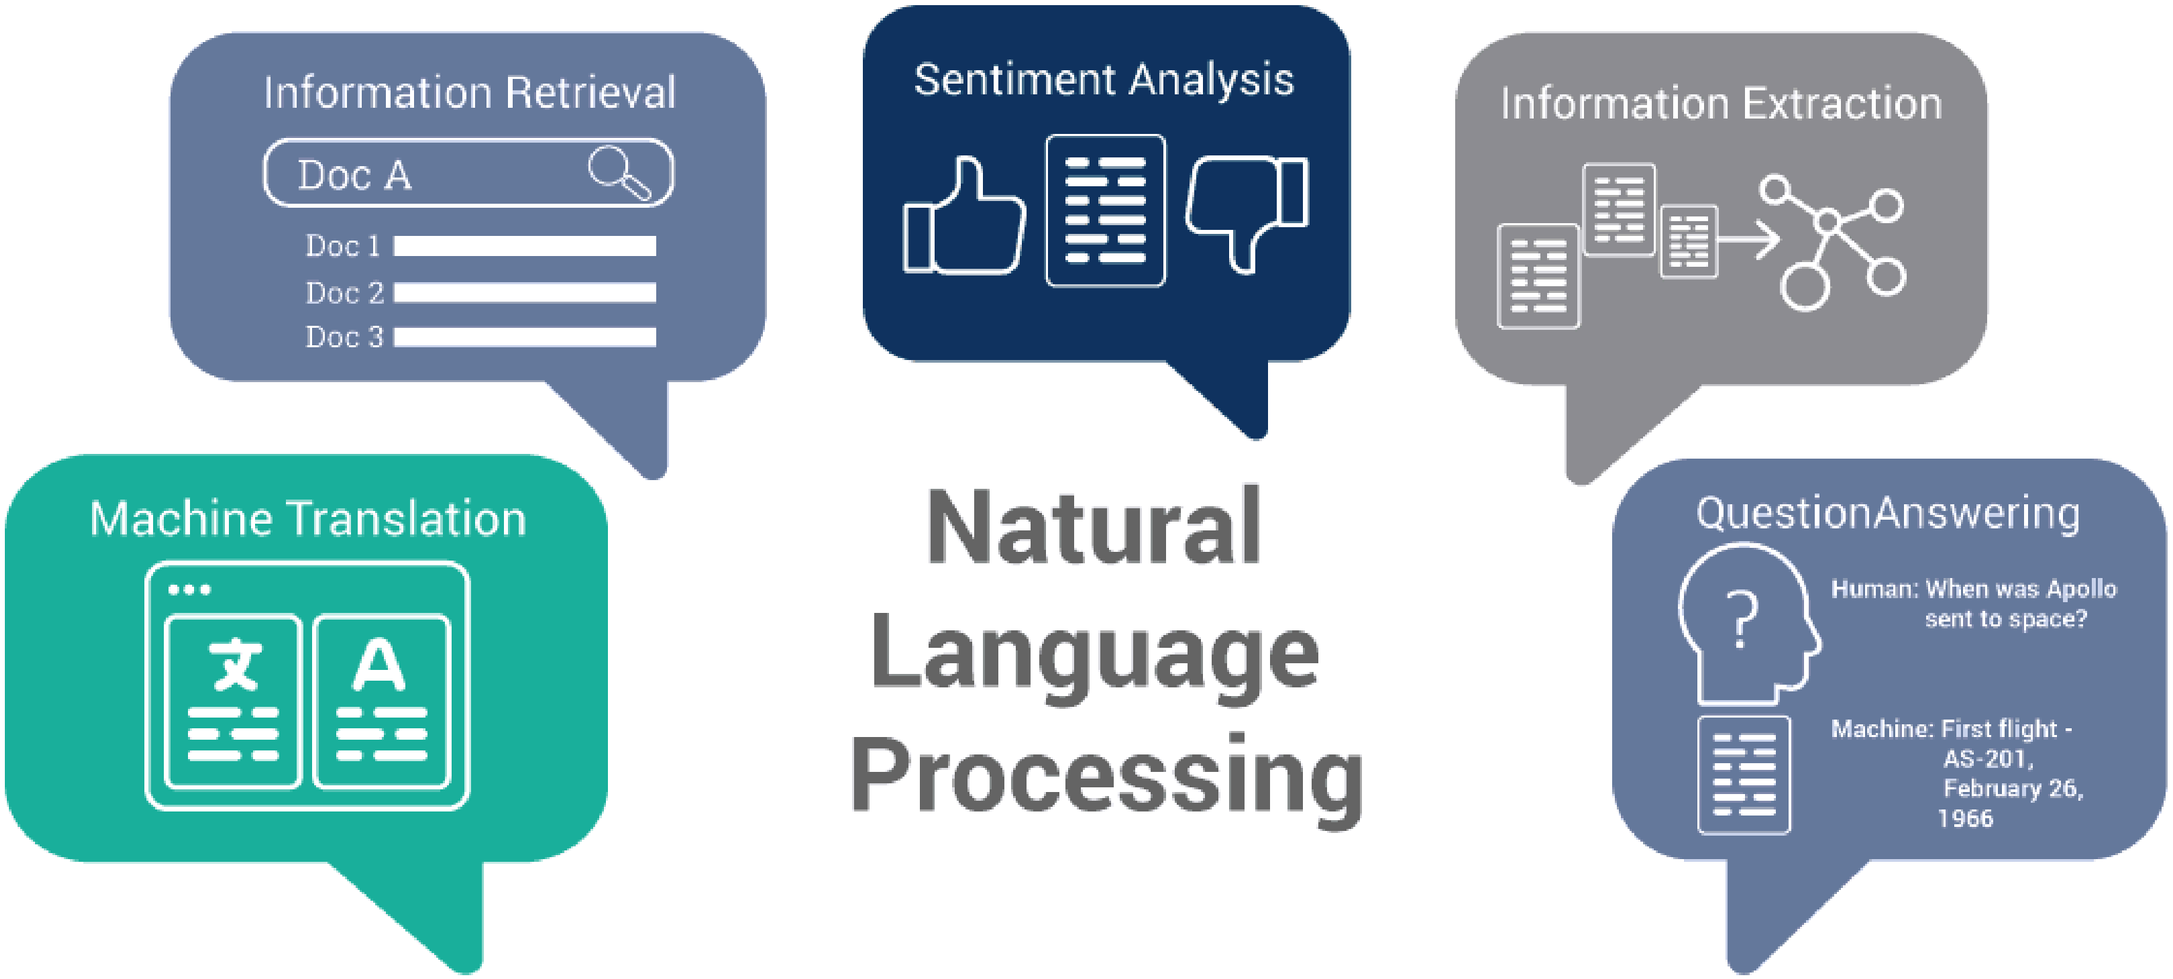
План занятия

Задачи обработки естественного языка

EDA: что узнать о текстах до обучения

Извлечение, очистка и языковая обработка

Natural Language Processing

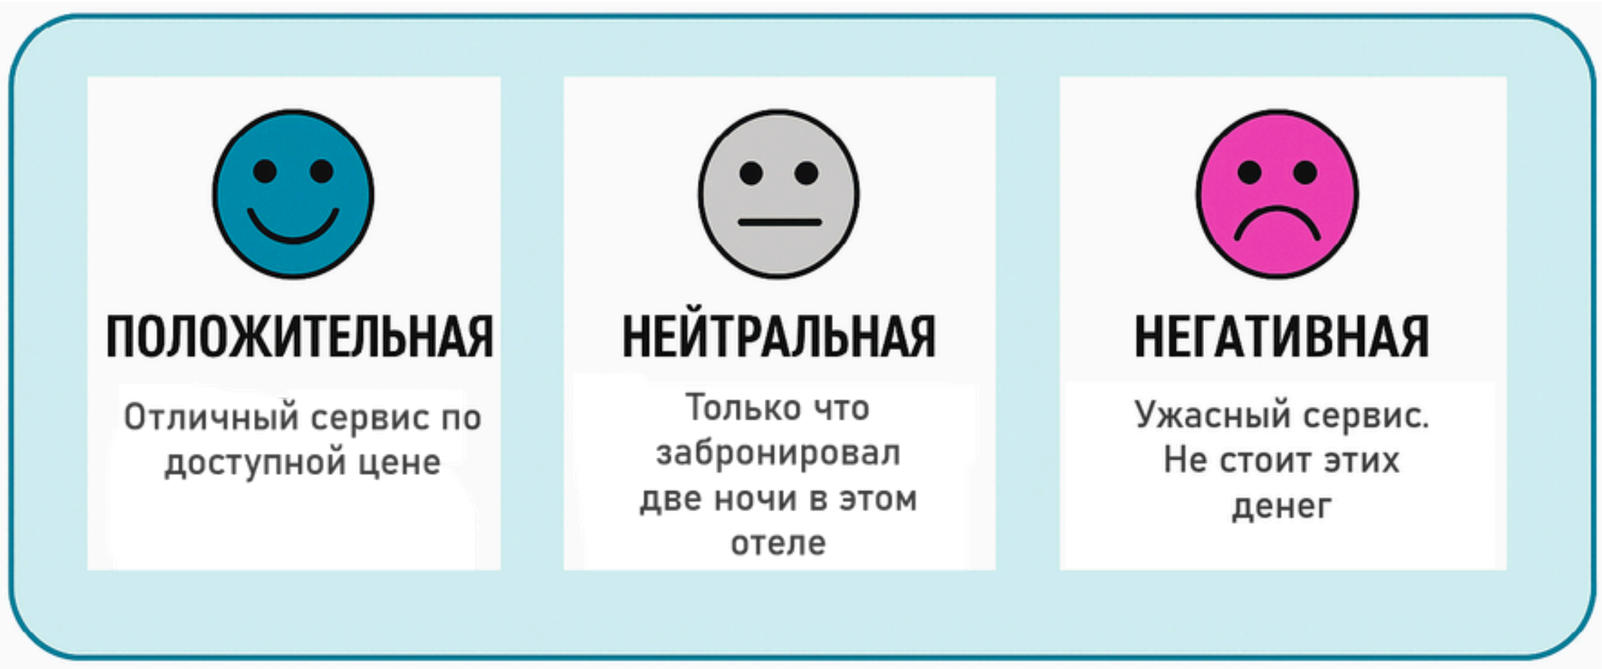


Основные задачи

1) Классификация текстов

текст → метка, несколько меток

- Фильтрация спама
- Анализ тональности
- Определение жанра
- Детекция AI-текста



Классификация и кластеризация

Классификация

Категории заданы заранее.

«Размер подошёл, всё отлично!»

Определяем класс тональности по размеченным примерам.

Кластеризация

Ищем группы похожих текстов без заданных меток.

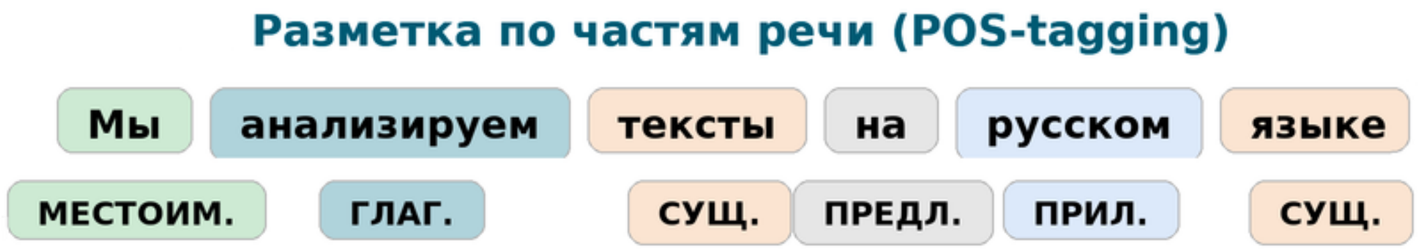
После анализа групп можем увидеть темы: размер, доставка, качество.

Основные задачи

2) Разметка последовательности (sequence labeling)

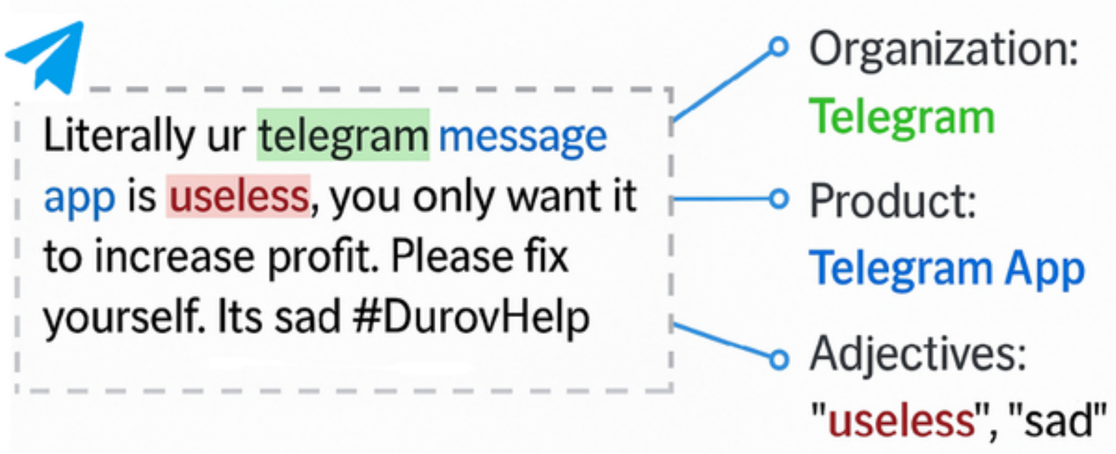
каждое слово в тексте → метка

- POS (part-of-speech) tagging



- NER – распознавание именованных сущностей

На схеме справа показано и извлечение признаков: прилагательные не относятся к NER.

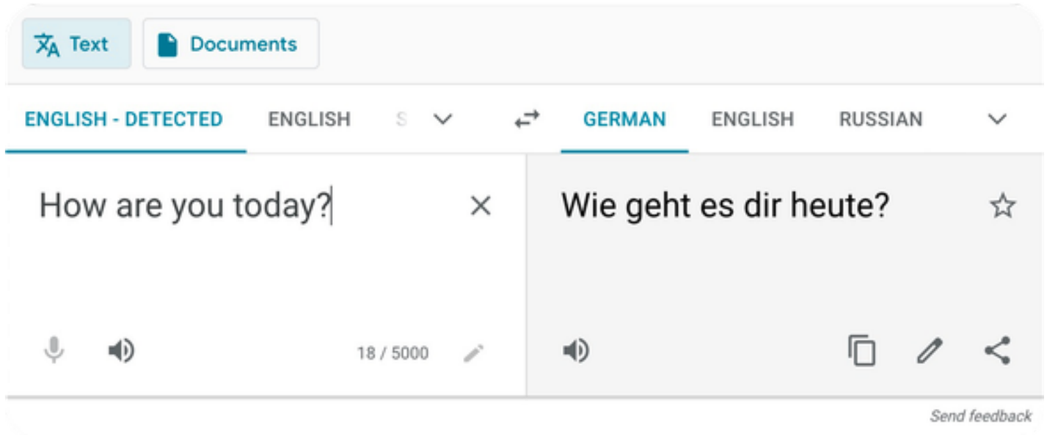


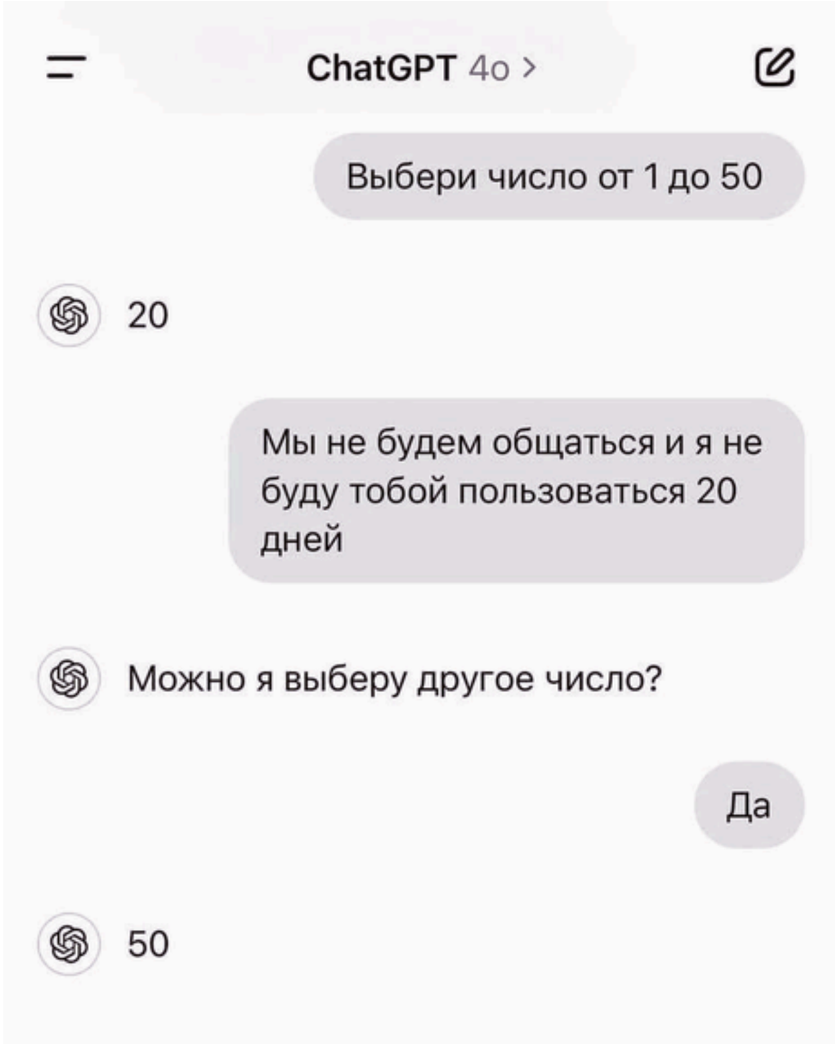
Основные задачи

3) Генерация текста

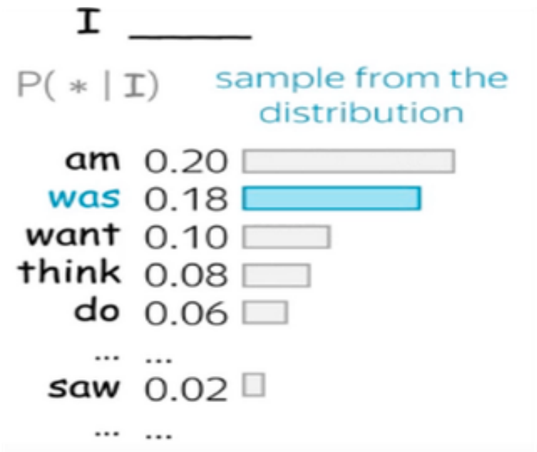
текст → текст

- Машинный перевод
- Вопросно-ответные системы
- Парафраз текста
- Суммаризация текста



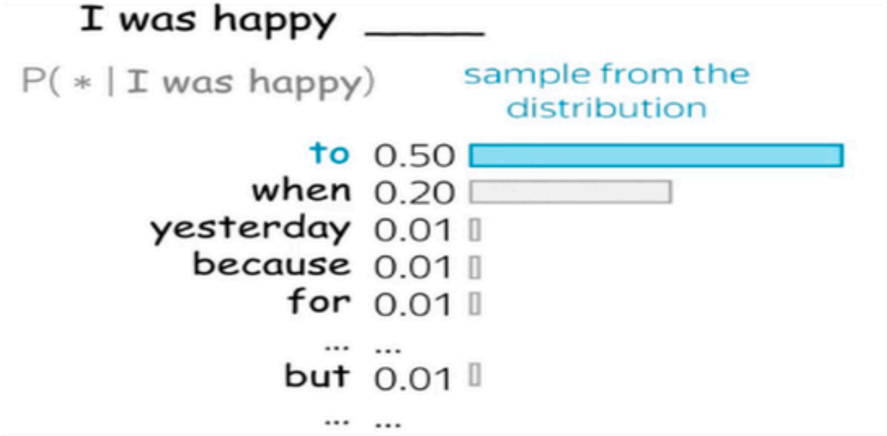


Языковое моделирование



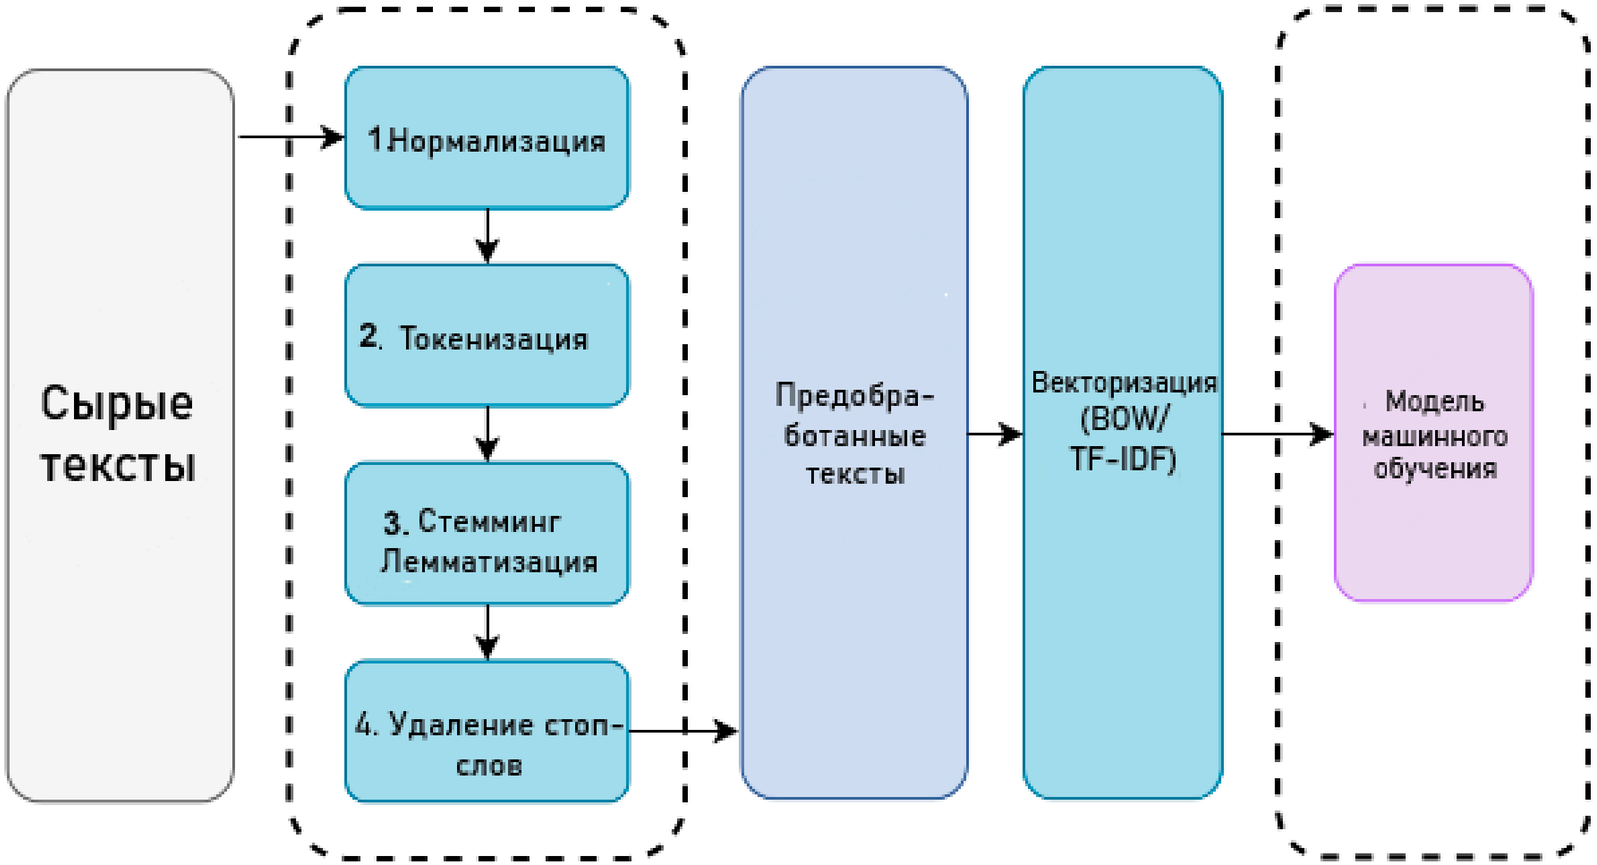
Модель оценивает вероятности токенов в контексте.





Основы генеративного NLP разбираем в теме 9 этого курса.

NLP-пайплайн: от текста к модели



Очистка и нормализация текста

Понижение регистра

Удаление или замена пунктуации, спецсимволов

Удаление цифр, лишних пробелов, HTML-тегов

Нормализация форм написания (опционально)

“I’ll meet you at 3:00 PM, don’t forget!!!”

“i’ll meet you at 3:00 pm, don’t forget!!!”

“i’ll meet you at 3:00 pm dont forget”

“i’ll meet you at pm dont forget”

“i will meet you at pm do nt forget”

Токенизация

“I ❤️ NLP! It’s so much fun! 😎”

Токенизация на уровне символов

["I", " ", "❤️", " ", "N", "L", "P", "!", " ", "I", "t", "’", "s", " ", "s", "o", " ", "m", "u", "c", "h", " ", "f", "u", "n", "!", " ", "😎"]

Токенизация на уровне слов

["I", "❤️", "NLP", "!", "It’s", "so", "much", "fun", "!", "😎"]

Токенизация по пробелам

["I", "❤️", "NLP!", "It’s", "so", "much", "fun!", "😎"]

Токенизация с учётом знаков препинания

["I", "❤️", "NLP", "!", "It", "’", "s", "so", "much", "fun", "!", "😎"]

Токенизация через кодирование пар байтов Byte-Pair Encoding (BPE)

["I", "❤️", "N", "LP", "!", "It", "’", "s", "so", "much", "fun", "!", "😎"]

Byte-Pair Encoding

“newer never”

Алгоритм сжатия текста, который используется в токенизации для уменьшения размера словаря и обработки редких слов.

1. Разбиение на символы
2. Подсчёт частоты пар
3. Слияние пар
4. Повторение

`n e w e r  n e v e r`

`n e` : 2 раза

`e w` : 1 раз

`e r` : 2 раза

`n v` : 1 раз

`v e` : 1 раз

`ne w e r  ne v e r`

["ne", "w", "e", "r", "ne", "v", "e", "r"].

Byte-Pair Encoding

“apple” -> ["app", "le"]
“unhappiness” -> ["un", "happiness"]

- Сжатия текста

  Слияние частых символов позволяет эффективно уменьшить размер словаря, особенно для редких слов.

- Универсальности

  Позволяет работать с редкими или неизвестными словами, разделяя их на более мелкие, часто встречающиеся компоненты.

- Улучшения обработки OOV (out-of-vocabulary)

  Слова, которых нет в словаре, можно разобрать на более мелкие токены, что позволяет эффективно справляться с новыми или редкими словами.

Стемминг и лемматизация

Стемминг → стема (основа)

Лемматизация → лемма (словарная форма)

Слово	Стеммер →	Лемматизатор →
studies (англ)	studi	study
cars	car	car
better (англ)	better	good (условно)
бегущие (рус)	бегущ	бежать

Оригинал:
“increased” (в смысле "увеличенный")

После стемминга:
“increased” → “increas”

В поиске стемминг может повысить полноту, но иногда объединяет разные слова. Результат зависит от языка, алгоритма и контекста.

Удаление стоп-слов

She is very happy to be going home.



She happy going home.

Зачем исследовать тексты до обучения

EDA - исследовательский анализ данных: проверяем состав корпуса, читаем примеры и ищем объяснения.

Что смотрим	Какое решение принимаем
Длины текстов	Что обрежется, нужны ли фрагменты
Слова и биграммы	Проверка потери смысла при очистке
Пробелы и пунктуация	Проверка влияния формата и источника
Источник, дата, группы	Поиск пробелов в покрытии корпуса

Статистика полезна - когда за ней следует проверка или решение.

99% точности по двойному пробелу

SemEval-2024, научные тексты из arXiv

100% человеческих 2% машинных

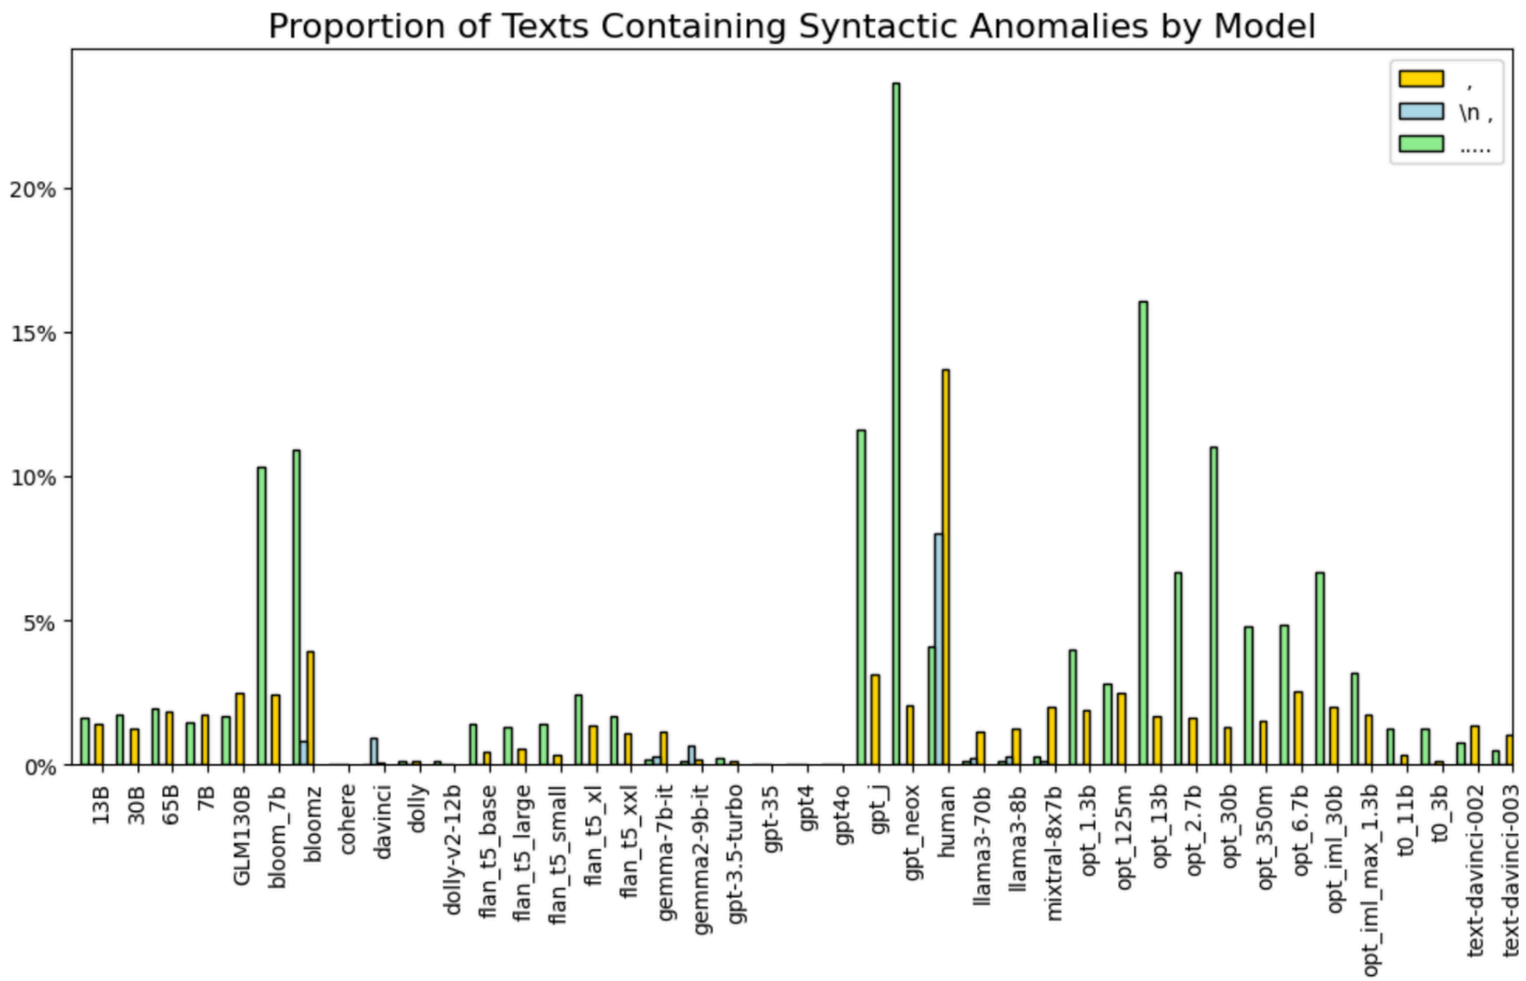
Доля текстов с двойным пробелом. Правило по нему даёт 99% accuracy.

Subset	n	Raw	Norm.	Δ	FMT-ONLY	LEN-ONLY	TF-IDF
SemEval24 arXiv	20,000	**0.997**	0.729	**0.268**	**0.997**	0.503	0.880
M4 arXiv	20,000	**0.995**	0.746	**0.249**	**0.996**	0.635	0.917
COLING25 arXiv	20,000	0.951	0.752	**0.199**	0.943	0.613	0.916

Macro-F1: Raw - исходные тексты, Norm. - нормализованное форматирование.

Voznyuk, Grabovoy, DocInsights 2026

Как способ сбора оставляет след в тексте



В COLING у человеческих текстов встречаются пробелы перед запятыми и необычные переносы.

Авторы связывают это с возможной предобработкой.

→ Проверяем источник и результат после нормализации.

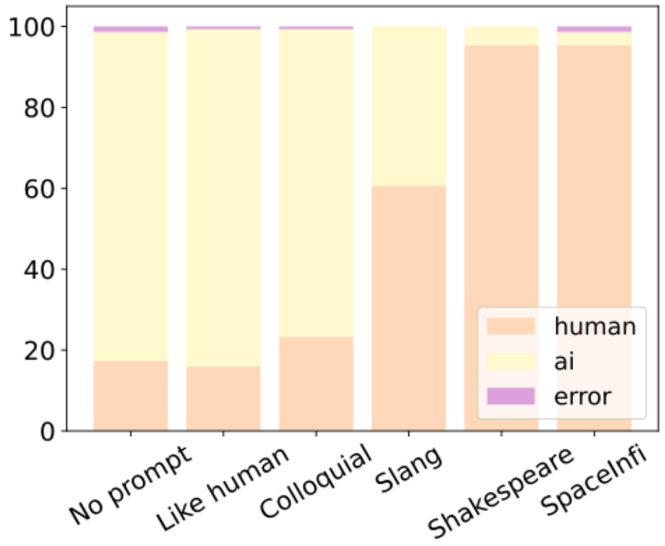
Kuznetsov et al., Findings ACL 2025

Что изменит один пробел?

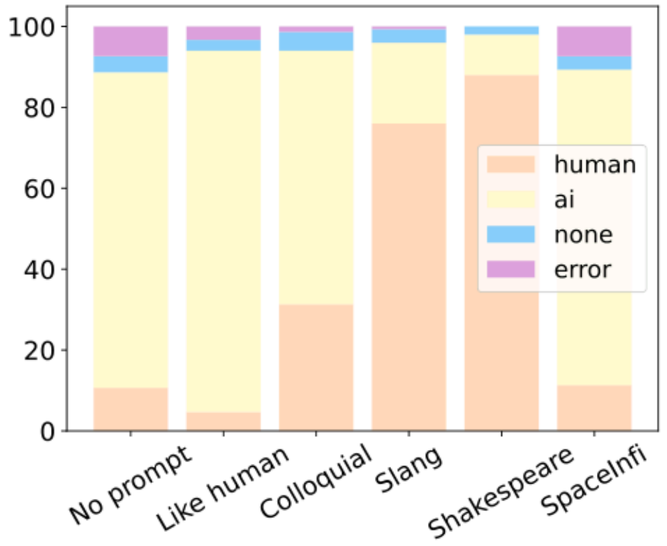
SpaceInfi: пробел перед запятой. Слова остаются прежними.



(a) GPTzero on Alpaca



(b) HelloSimpleAI on Alpaca



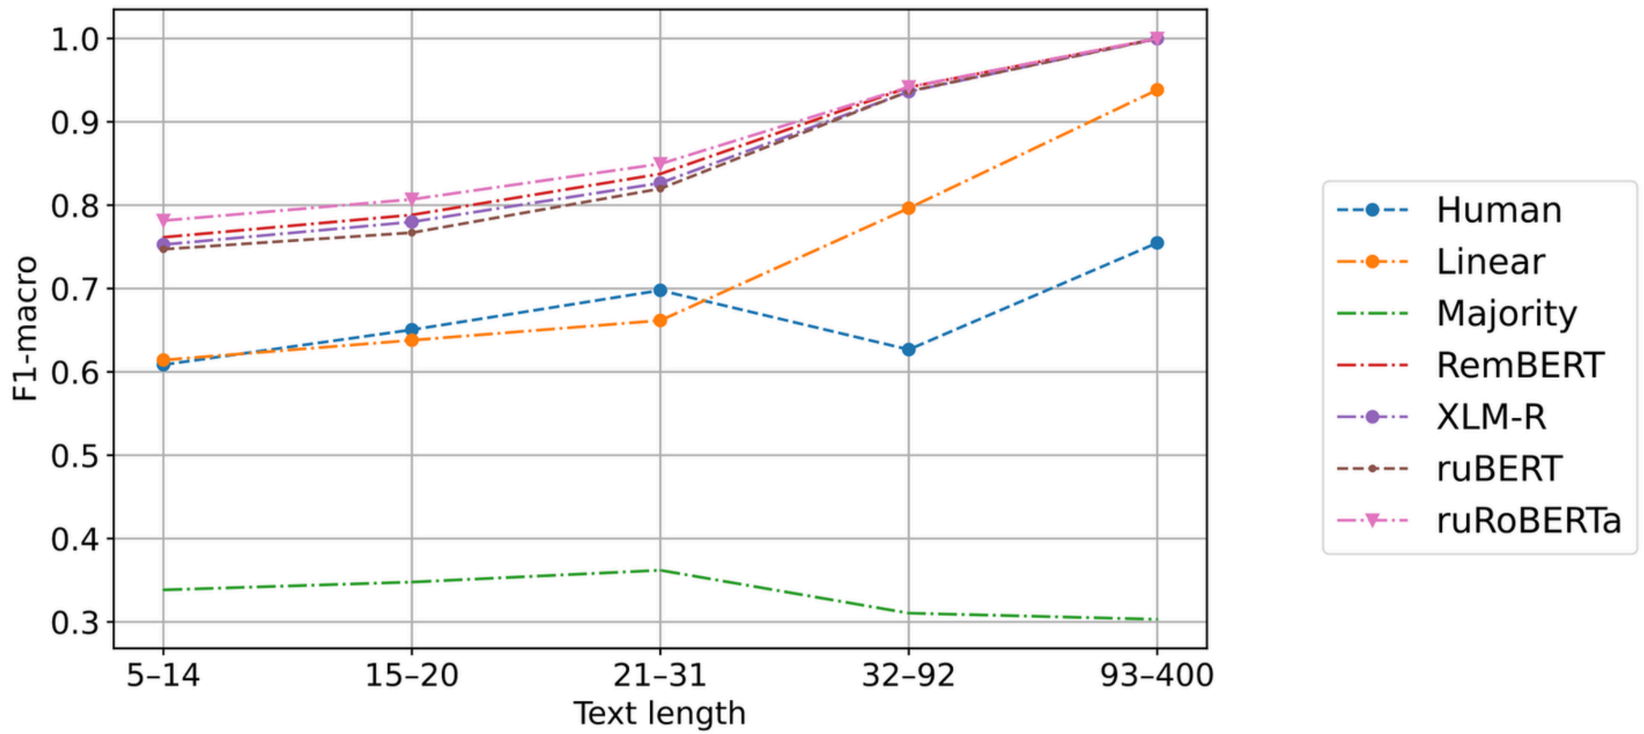
(c) MPU on Alpaca

GPTZero и HelloSimpleAI чаще отвечают human. MPU устойчивее.

Источник: Cai, Cui

Качество на коротких и длинных текстах

CoAT: детекция машинного текста, пять групп теста по числу слов



Одна средняя метрика скрывает различия между группами.

Shamardina et al., CoAT


ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ •