

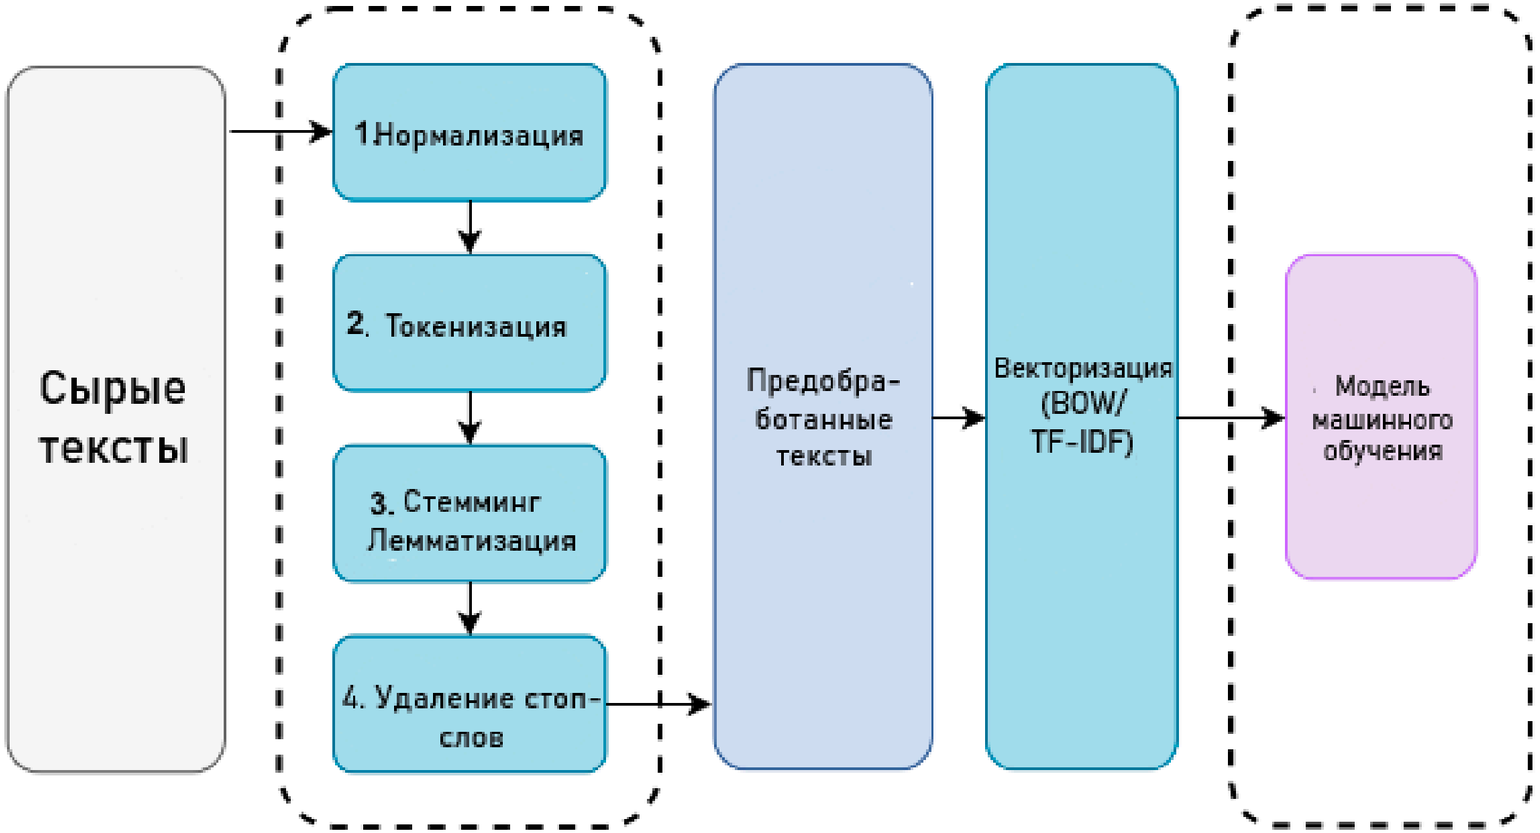
Факультет компьютерных наук

Аналитика больших данных

Москва
2026-2027

Разреженные представления и интерпретируемые бейзлайны

NLP-пайплайн: от текста к модели



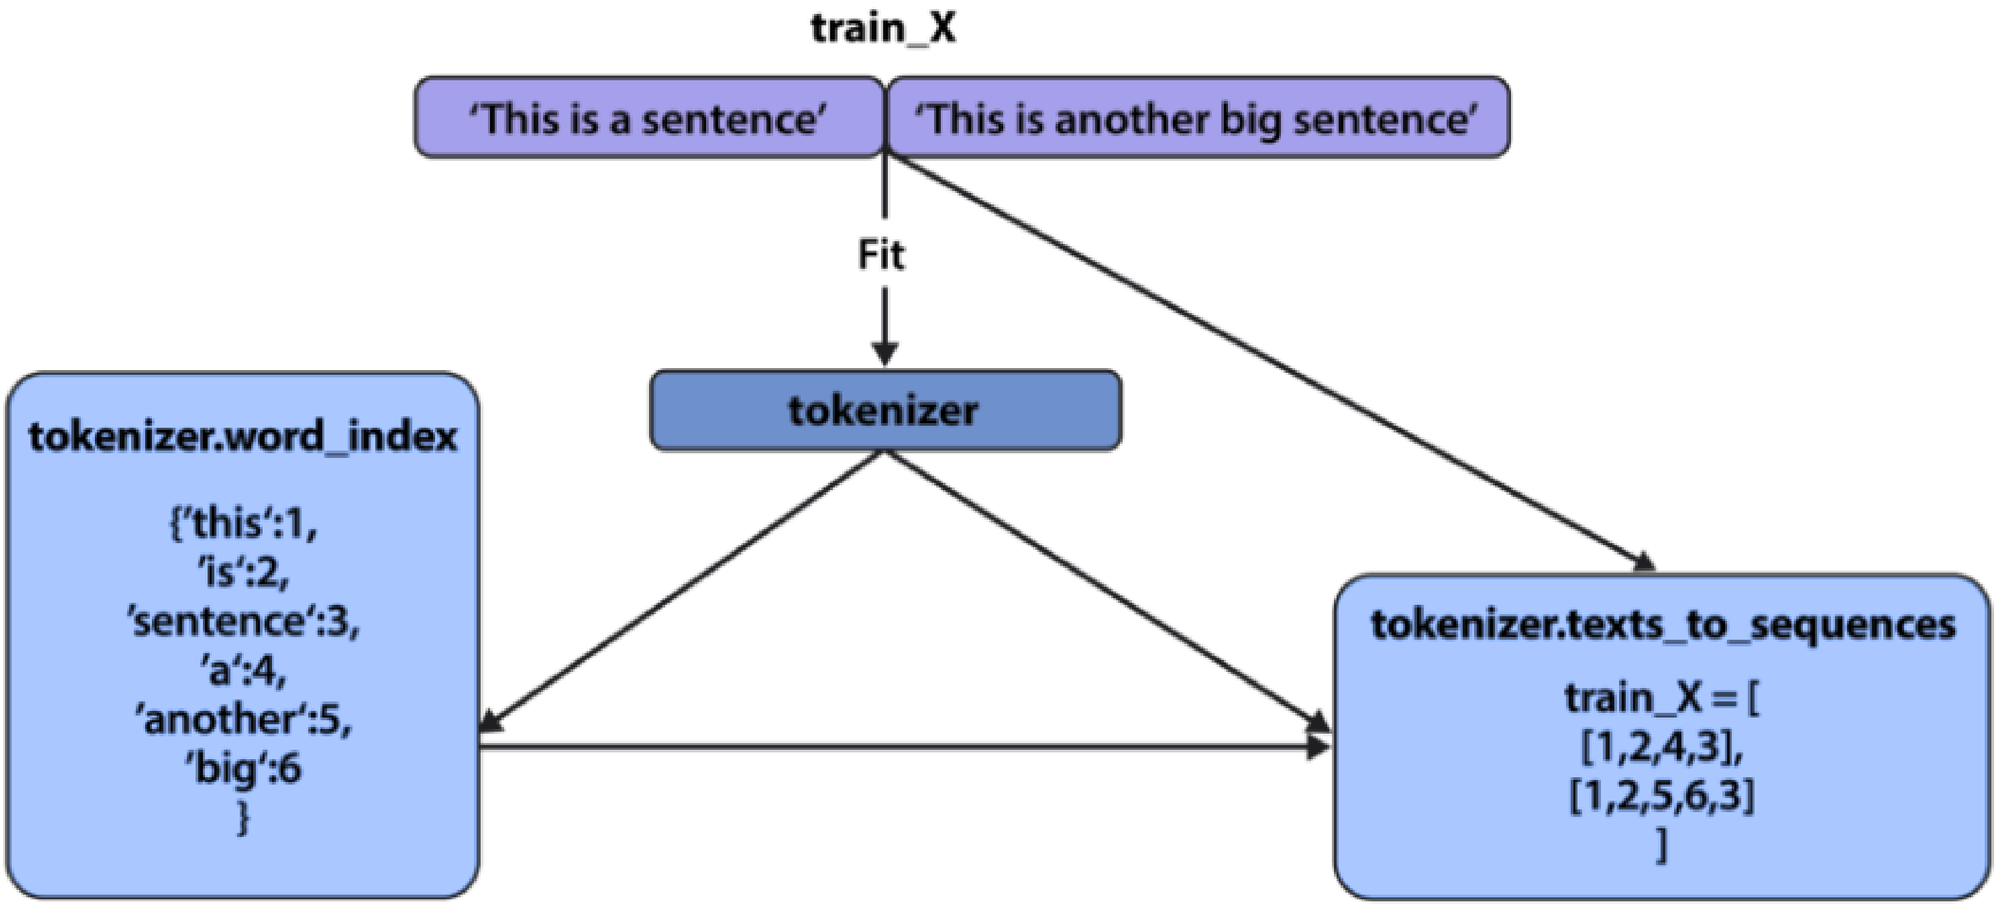
Разреженные представления текста

Платье хорошее, ткань утеплённая

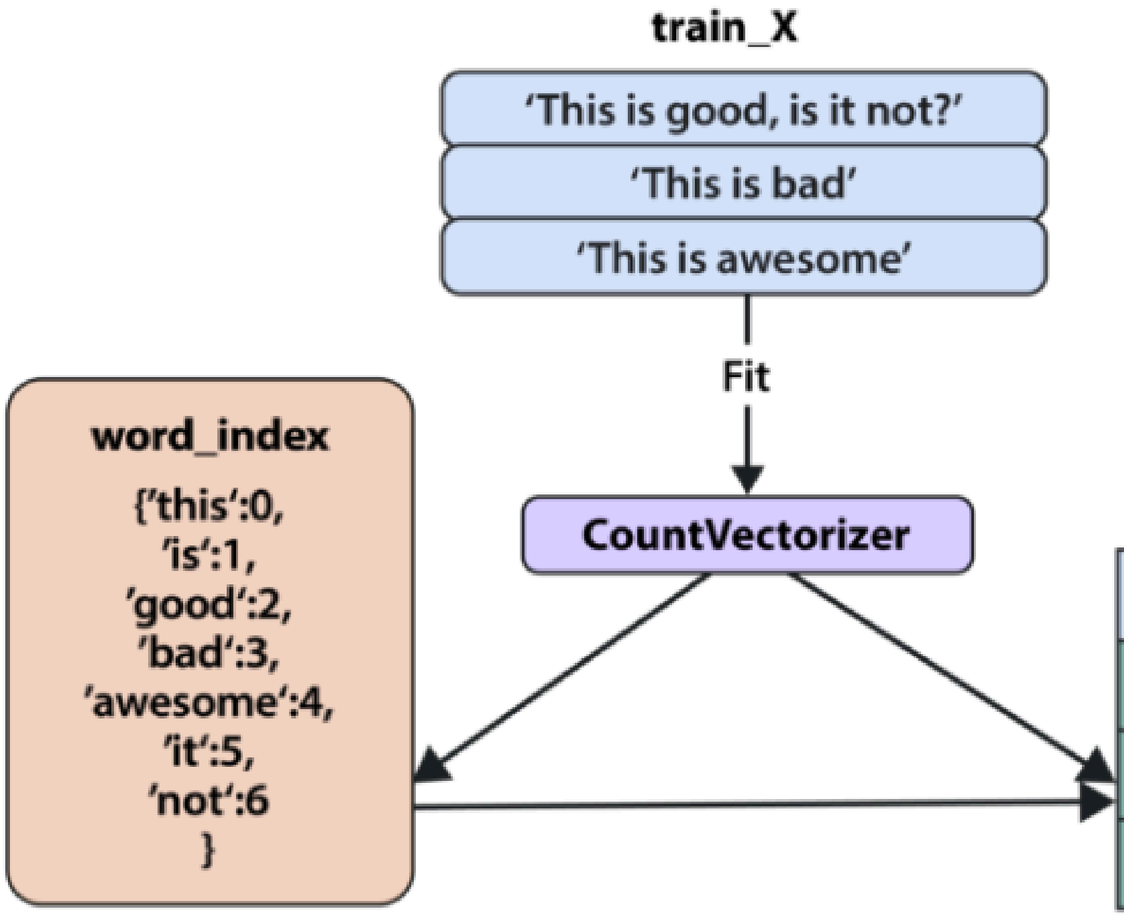
Текст ⟺ Признаки ⟺ Матрица X ⟺ Модель ⟺ Тональность



Преобразование текста в признаки



Bag-of-Words aka мешок слов



Features

This	is	good	bad	awesome	it	not
1	2	1	0	0	1	1
1	1	0	1	0	0	0
1	1	0	0	1	0	0

Bag-of-Words

75245

Платье хорошее, ткань утеплённая

77284

очень хорошее **платье**, точно в размер, **очень** красивое летнее **платье**:))

38918

Получила **платье** и расстроилась. **Платье очень** короткое, скорее не **платье** , а **туника**

Столбцы - элементы словаря

ID	платье	хорошее	очень	туника
75245	1	1	0	0
77284	2	1	2	0
38918	3	0	1	1

Показаны 4 из 15 признаков.

Биграммы сохраняют соседство слов

*Платье очень короткое, скорее **не платье** , а **туника***

Униграммы	платье очень короткое скорее не платье туника
Примеры биграмм	«платье очень» «очень короткое» «скорее не» «**не платье**» «платье туника»

Больше локального контекста - больше редких признаков

Term Frequency – Inverse Document Frequency

Метод, где наибольший вес получают слова, которые часто встречаются в *одном конкретном* документе (высокий TF), но редко в *целом корпусе* (высокий IDF), что и выделяет их как уникальные и важные маркеры.

$$\mathrm{TF}(t, d) = \frac{\text{число вхождений слова } t \text{ в документ } d}{\text{общее число слов в документе } d}$$

$$\mathrm{IDF}(t, D) = \log\left(\frac{\text{общее число документов}}{\text{число документов, где встречается слово } t}\right)$$

> Логарифмирование здесь проводится с целью уменьшить масштаб весов, ибо зачастую в корпусах присутствует очень много текстов.

В итоге каждому слову t из текста d теперь можно присвоить вес

$$\text{TF-IDF}(t, d, D) = \mathrm{TF}(t, d) \times \mathrm{IDF}(t, D)$$

Интерпретируем:

- Если слово часто встречается в одном документе, но редко — в остальных, то оно важно для этого документа.
- Если слово встречается везде, например, такие как "и", "что", "это", то оно не помогает отличать один текст от другого — TF-IDF даст ему низкий вес.

Term Frequency – Inverse Document Frequency

$$w_{x,} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$$

TF-IDF

Термин x в документе y

$tf_{x,y}$ = частота x в документе y

df_x = число документов, содержащих x

N = общее число документов

TF-IDF всё еще - всегда

Место	Входные данные (Features)	Модель (Model)	Функция потерь (Loss)	Hitrate@3
11	`app_name` + `shortDescription` + `full_description`	`cointegrated/rubert-tiny2`	Стандартная	0.2846
10	`app_name`	`FacebookAI/xlm-roberta-base`	Стандартная	0.5576
9	`app_name`	`FacebookAI/xlm-roberta-base`	С весами для классов	0.7017
8	`app_name` + `shortDescription`	`FacebookAI/xlm-roberta-base`	Стандартная	0.7714
7	`app_name` + `shortDescription`	`FacebookAI/xlm-roberta-base`	С весами для классов	0.8409
6	`app_name` + `shortDescription` + `full_description`	TF-IDF + LSA + Logistic Regression	С весами для классов	0.8638
5	`app_name` + `shortDescription` + `full_description`	`FacebookAI/xlm-roberta-base`	Стандартная	0.8941
4	`app_name` + `shortDescription` + `full_description`	TF-IDF + ClassifierChain(LR)	С весами для классов	0.9092
3	`app_name` + `shortDescription` + `full_description`	`FacebookAI/xlm-roberta-base`	С весами для классов	0.9165
2	`app_name` + `shortDescription` + `full_description`	`intfloat/multilingual-e5-base`	С весами для классов	0.9196
1	**`app_name` + `shortDescription` + `full_description`**	**TF-IDF + Logistic Regression**	**С весами для классов**	**0.9224**

TF-IDF - *вариант scikit-learn*

В нашей конфигурации TF(t,d) = count(t,d)

Базовый IDF

$$IDF = \ln(N / df)$$

IDF в scikit-learn

$$IDF = \ln((1 + N) / (1 + df)) + 1$$

+1 внутри дроби - сглаживание

+1 после ln - ненулевой вес
для слов во всех документах

Слово	Базовый IDF	IDF в scikit-learn
платье	0	1
туника	1.099	1.693

TF-IDF объединяет частоту и редкость

75245

Платье хорошее, ткань утеплённая

77284

очень хорошее **платье**, точно в размер, **очень** красивое летнее **платье**:))

38918

Получила **платье** и расстроилась. **Платье очень** короткое, скорее не **платье** , а **туника**

Слово	TF	IDF	TF × IDF
платье	3	1.000	3.000
очень	1	1.288	1.288
туника	1	1.693	1.693

L2-нормировка меняет длину вектора

Признак	До L2	После L2
платье	3.000	0.568
очень	1.288	0.244
туника	1.693	0.321

Делим все 15 координат на 5.278

Направление сохраняется, длина ненулевого вектора становится равна 1

Naive Bayes (наивный Байес)

Интуиция: “какие слова типичны для класса?”

$$P(x \mid y = k) = P(x_1, \ldots, x_n \mid y = k) \approx \prod_{t=1}^{n} P(x_t \mid y = k)$$

$$y^* = \arg\max_k P(x, y = k) = \arg\max_k P(y = k) \cdot P(x \mid y = k)$$

$$\log P(x, y = k) = \log P(y = k) + \sum_{t=1}^{n} \log P(x_t \mid y = k)$$

Naive Bayes, Text Classification, and Sentiment

Naive Bayes (наивный Байес)

Интуиция: “какие слова типичны для класса?”

Как именно устроены признаки x_t

Bernoulli NB: $x_t \in 0, 1$ - слово встретилось/не встретилось”

Multinomial NB: $x_t \in \mathbb{N}$ - "сколько раз встретилось слово" (самый частый вариант для текстов)

Как оцениваются вероятности и почему нужно сглаживание

Иначе получаются нули.

- prior: $p(y = k) = \frac{N_k}{N}$
- likelihood (пример для MultinomialNB):

  $$p(w \mid y = k) = \frac{N_{w,k} + \alpha}{\sum_{w' \in V} N_{w',k} + \alpha |V|}$$

  где α - сглаживание Laplace/add-α

Naive Bayes, Text Classification, and Sentiment

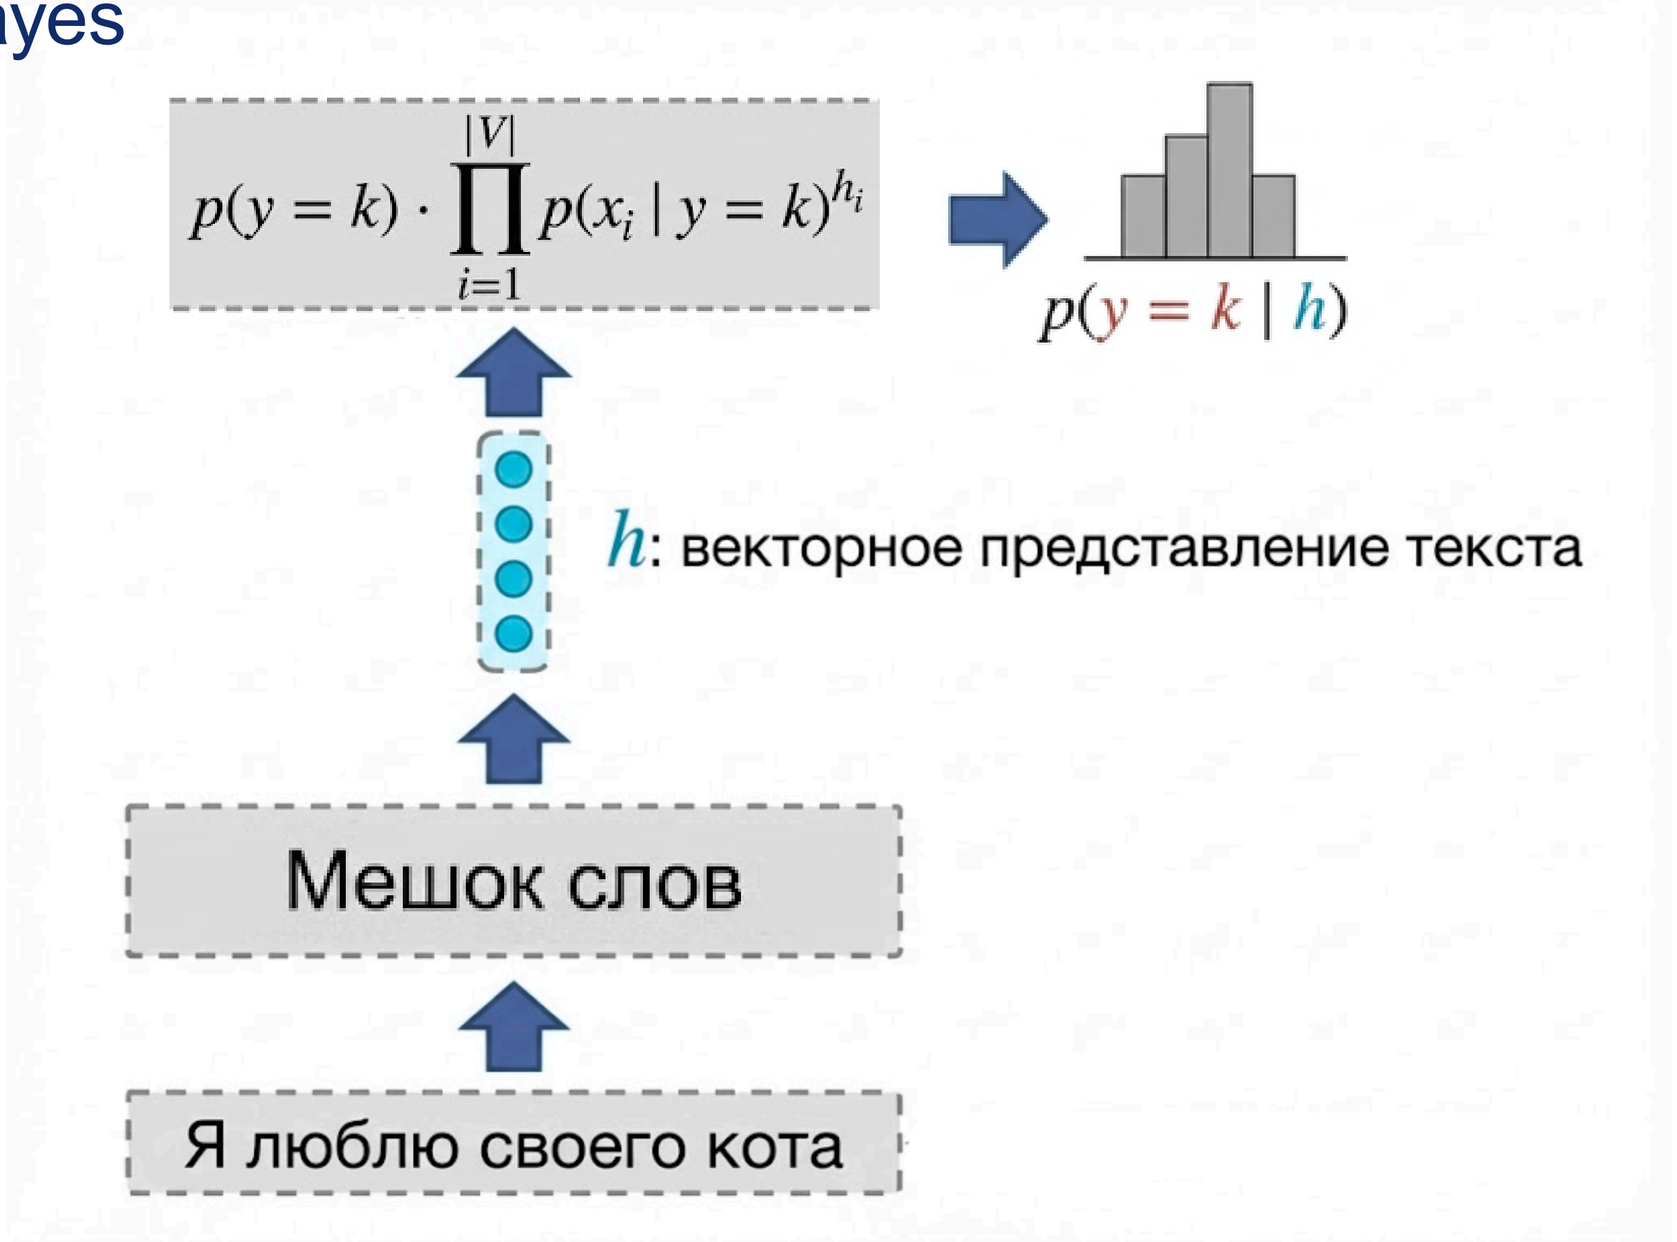
Что если слово ни разу не встречалось?

$$N(\text{кракозябрик}, y = +) = 0$$

$$p(\text{«очень милый кракозябрик»} \mid y = +) =$$
$$= p(\text{«очень»} \mid y = +) \cdot p(\text{«милый»} \mid y = +) \cdot p(\text{«кракозябрик»} \mid y = +) = 0$$

$$p(w \mid y = k) = \frac{N(w, y = k)}{\sum_{w' \in V} N(w', y = k)} = \frac{0}{\text{что-то положительное}} = 0$$

Naive Bayes


$p(y = k) \cdot \prod_{i=1}^{|V|} p(x_i \mid y = k)^{h_i}$
$p(y = k \mid h)$
h: векторное представление текста
Мешок слов
Я люблю своего кота

Наивный Байес: слова внутри классов

Сколько раз слово «хорошее» встретилось в train?

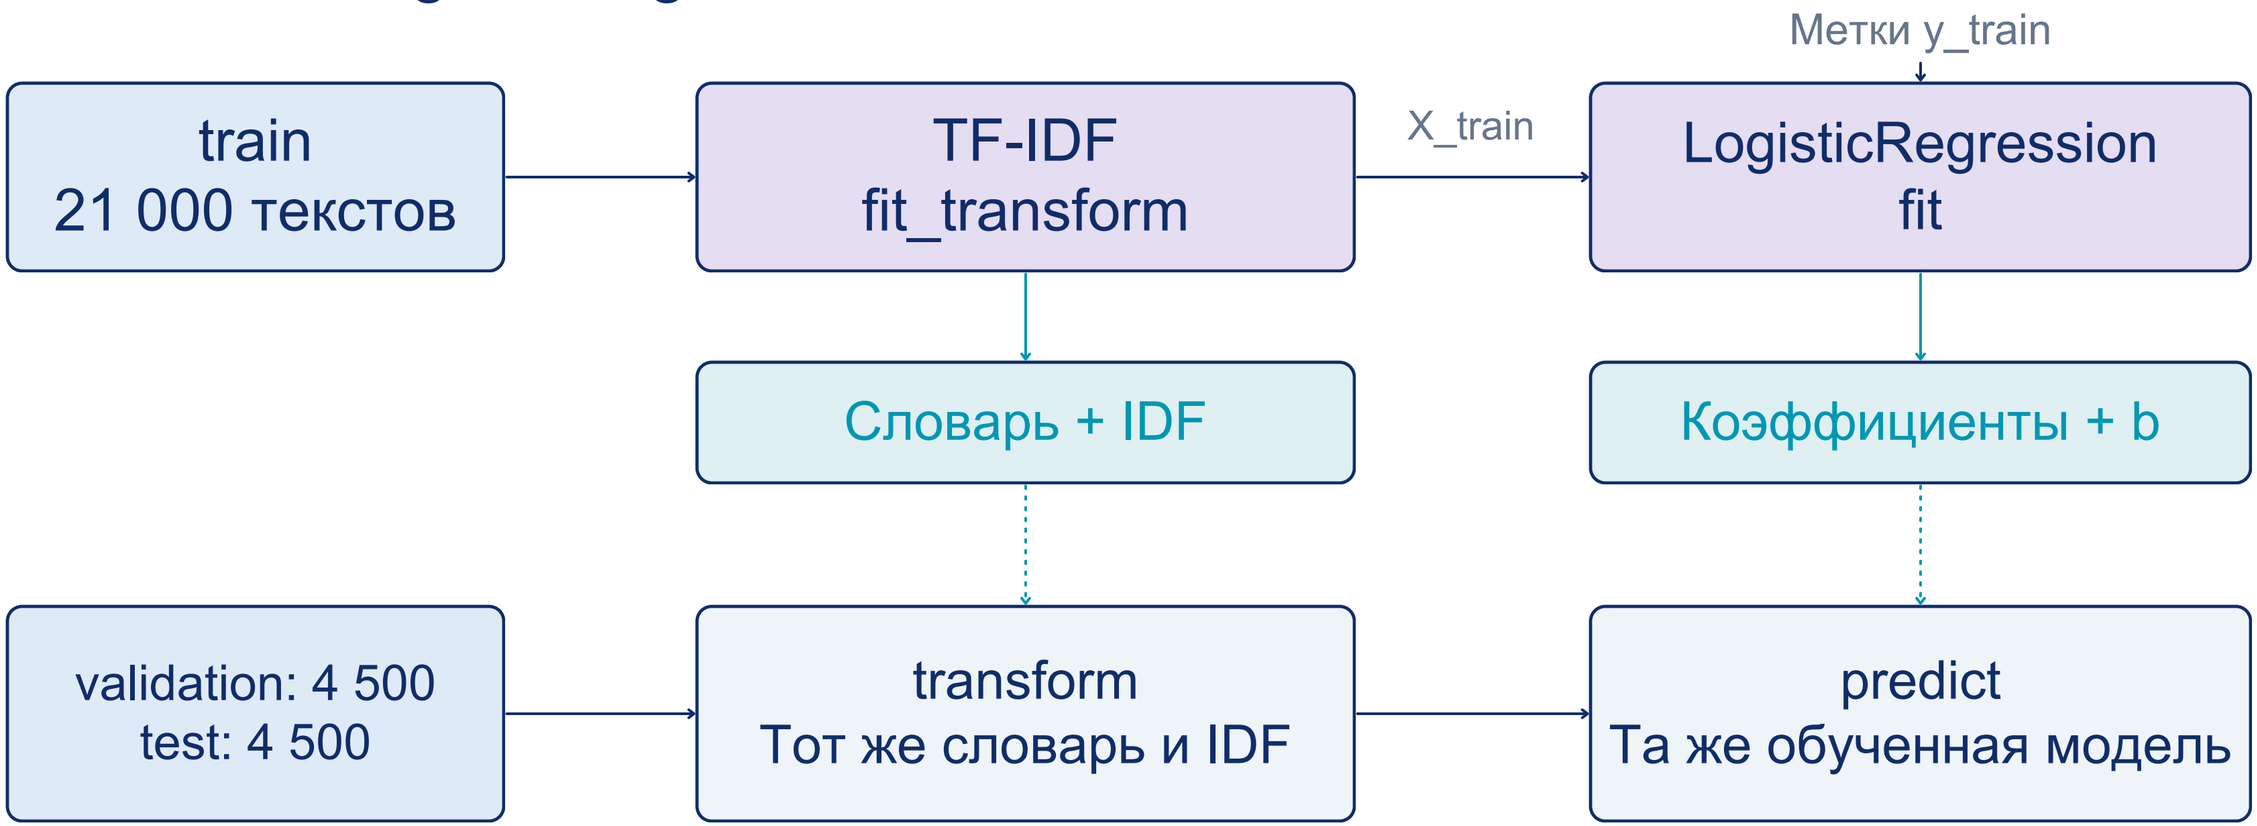
Класс	**negative**	**neutral**	**positive**
Частота «хорошее»	68	192	661
P(«хорошее» | класс)	0.000454	0.001421	0.005225

Логистическая регрессия

x - из текста **w - из обучения** **b - свободный член**

Признак	x	w positive, j	x × w positive, j
клеенка	0.414	-0.199	-0.082
на вид	0.325	0.528	0.171
запах просто	0.448	0.148	0.066

Счетчик + LogisticRegression



validation - выбор настроек
test - итоговая оценка

Матрица ошибок

Строка - метка, столбец - прогноз

	negative	neutral	positive
negative	1040	419	36
neutral	349	977	159
positive	33	199	1288

Precision positive = 1288 / 1483 = 0.869

Recall positive = 1288 / 1520 = 0.847

F1 = 2PR / (P + R) = 0.858

Macro-F1 = среднее F1 классов
Для этой модели: 0.735